# Test de Wald pour l'égalité des moyennes

Maxence Caucheteux, Hassen Kallala, Armand De Cacqueray, Sabri Bouafia

École des ponts et chaussées

8 janvier 2025



## Introduction

## Objectifs

- But : déterminer si des moyennes sont égales ou non.
- Formellement, on dispose de deux échantillons  $\mathbf{X}_1 = (X_{1,1}, \dots, X_{1,n_1})$  et  $\mathbf{X}_2 = (X_{2,1}, \dots, X_{2,n_2})$ .

• On pose 
$$\mu_1 = \mathbb{E}(X_{1,1})$$
 et  $\mu_2 = \mathbb{E}(X_{2,1})$ 

• A-t-on  $\mu_1 = \mu_2$  ?

# Hypothèses

## Choix des hypothèses

$$H_0 = \{\mu_1 = \mu_2\}, \quad H_1 = \{\mu_1 \neq \mu_2\}$$

#### Remarques:

- Test bilatéral
- De base, on suppose que les moyennes sont égales.
- On veut éviter de dire que les moyennes sont différentes alors que ce n'est pas le cas.
- On aurait également pu effectuer un test unilatéral via le choix de  $H_0 = \{\mu_1 \leq \mu_2\}$  et  $H_1 = \{\mu_1 > \mu_2\}$  (la pertinence du choix dépend de la situation).

# Construction de la statistique de test

Pour  $j \in \{1, 2\}$ , on pose :

- $\mu_j = \mathbb{E}(X_{j,1})$
- $\sigma_j^2 = \mathbb{V}(X_{j,1})$  (non connus)
- $Z_{n_1,n_2} = \overline{X}_{1,n_1} \overline{X}_{2,n_2}$  (différence empirique des moyennes des deux échantillons)

#### Normalité asymptotique

On peut montrer que :

$$rac{Z_{n_1,n_2}-(\mu_1-\mu_2)}{\sqrt{\mathbb{V}(Z_{n_1,n_2})}} \xrightarrow[n_1,n_2 o\infty]{\mathsf{loi}} \mathcal{N}(0,1)$$

Mais on ne connaît pas  $\sigma_1$  et  $\sigma_2$ .



# Construction de la statistique de test

C'est pourquoi on introduit les variances empiriques :

$$\forall j \in \{1,2\}, \quad \hat{\sigma}_{j,n_j}^2 = \frac{1}{n_j} \sum_{k=1}^{n_j} (X_{j,k} - \overline{X}_{j,n_j})^2$$

#### Forte consistance

On a:

$$\frac{\sqrt{\frac{\hat{\sigma}_{1,n_1}^2}{n_1} + \frac{\hat{\sigma}_{2,n_2}^2}{n_2}}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \xrightarrow[n_1, n_2 \to \infty]{\text{p.s.}} 1$$

# Construction de la statistique de test

#### Région de rejet

Avec la région de rejet

$$W_n = \left\{ Y_n := \frac{|Z_{n_1, n_2}|}{\sqrt{\frac{\hat{\sigma}_{1, n_1}^2}{n_1} + \frac{\hat{\sigma}_{2, n_2}^2}{n_2}}} \ge \phi_{1-\alpha/2} \right\},\,$$

le test est consistant et de niveau asymptotique  $\alpha$ .

Rappel : 
$$H_0 = \{ \mu_1 = \mu_2 \}$$
 et  $H_1 = \{ \mu_1 \neq \mu_2 \}$ 

# Calcul de la p-valeur

### p-valeur

où  $F_G$  est la fonction de répartition de la gaussienne centrée réduite.

## Similarités avec le test de Wald à un échantillon

- Le test de Wald à deux échantillons généralise le test de Wald à un échantillon.
- Pour le test de Wald à un échantillon :  $H_0 = \{\mu = \mu_0\}$  et  $H_1 = \{\mu \neq \mu_0\}$  où  $\mu_0$  est fixé et connu.
- En prenant pour deuxième échantillon des variables aléatoires déterministes égales à  $\mu_0$  dans le test de Wald à deux échantillons, on retrouve le test de Wald à un échantillon.

# Présentation du problème

- Jeu de données : une liste d'élèves du collège dont on sait s'ils ont Internet chez eux ou pas et dont on connaît le nombre d'échecs aux examens passés.
- Le nombre d'échecs à des examens mesure en quelque sorte les performances de l'élève.
- Question : Les élèves sans accès à Internet réussissent-ils autant à l'école que les élèves qui ont accès à Internet ?



## Résultats

Échantillon	Élèves avec Internet	Élèves sans Internet
n	$n_1 = 827$	$n_2 = 217$
$\mu$	$\mu_1 = 0.24$	$\mu_2 = 0.36$
$\sigma$	$\sigma_1 = 0.62$	$\sigma_2 = 0.77$

Table – Tableau des statistiques des échantillons

#### Calcul de la p-valeur

On a:

p-valeur = 
$$0.034$$
 i.e.  $3.4\%$ 

On rejette  $H_0$ .

Rappel : 
$$\alpha = 5\%$$



# Pouvoir statistique du test

- On s'intéresse au pouvoir statistique du test
- On cherche à calculer  $\mathbb{P}_{\mu_1,\mu_2}(W_n)$
- On fixe les variances des deux échantillons et on trace le pouvoir en fonction de  $\Delta\mu=\mu_1-\mu_2$

# Expression du pouvoir statistique

#### Expression du pouvoir statistique


Le pouvoir statistique de ce test est donné par la formule suivante :

Statistical Power = 
$$1 - F_G \left( \phi_{1-\alpha/2} - \frac{\Delta \mu}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \right)$$

$$+ F_G \left( -\phi_{1-\alpha/2} - \frac{\Delta \mu}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \right)$$

où  $F_G$  est la fonction de répartition de la normale centrée réduite.

# Pouvoir statistique du test



## Conclusion à tirer du test

- On rejette l'hypothèse selon laquelle les élèves avec et sans Internet réussissent autant à l'école.
- Les élèves qui n'ont pas internet réussisent moins bien.

# Autre application : comparaison de proportions

- Il s'agit du cas particulier du modèle de Bernoulli.
- Les deux échantillons  $X_1$  et  $X_2$  suivent des lois de Bernoulli  $\mathcal{B}(p_1)$  et  $\mathcal{B}(p_2)$ .
- Question du type : est-ce que  $p_1 = p_2$ ? C'est-à-dire, est-ce que les deux groupes réussissent l'épreuve tout autant?
- Exemples d'application :
  - Effets cliniques : comparer l'efficacité de deux traitements.
  - Marketing : évaluer le taux de clics entre deux campagnes.
  - Éducation : comparer le taux de réussite de deux méthodes pédagogiques.
  - Production : tester la qualité de deux lots industriels.
  - Environnement : comparer le taux de survie de deux espèces en milieu contrôlé

# Autre application : comparaison de proportions

- Exemple du cours : Neymar a réussi 70 pénaltys sur 85 (82%)
   et Mbappé en a réussi 20 sur 25 (80%)
- Question : Neymar est-il meilleur que Mbappé au pénalty ?
- $p_1$  (resp.  $p_2$ ) : probabilité que Neymar marque un penalty (resp.  $p_2$ )
- Avec les hypothèses  $H_0=\{p_1\leq p_2\}$  et  $H_1=\{p_1>p_2\}$ ,  $H_0$  n'est pas rejeté à 5%

# Fin de l'exposé